




Evaluación Práctica de Sistemas RAG

El arte de medir la recuperación y la generación sin morir en el intento

AUDITORÍA DINÁMICA · FORMACIÓN TÉCNICA

El Enfoque Pedagógico: El Examen a Libro Abierto

Un sistema RAG se comporta como un alumno que se presenta a un examen con acceso a un manual completo. Sin embargo, el suspenso puede llegar por dos caminos completamente distintos.

✗ Fallo de Retrieval

El alumno leyó la página equivocada. El buscador vectorial recuperó documentos irrelevantes o incompletos. El LLM nunca tuvo la oportunidad de responder bien: la materia prima era defectuosa desde el inicio.

⚠ Fallo de Generation

Leyó la página correcta... pero redactó una mentira. El documento recuperado era el adecuado, pero el modelo generó una respuesta que contradice o extrapola más allá del contexto. Esto se llama **alucinación** y es el riesgo más difícil de detectar.

 Comprender esta distinción es el primer paso para auditar un sistema RAG de forma sistemática y eficaz.

MÓDULO I

La Puntería del Buscador

Métricas para auditar la base de datos vectorial y el proceso de Retrieval



Precision@k vs. Recall@k — La Analogía del Pescador

Ambas métricas se calculan sobre los **k primeros documentos recuperados** y responden preguntas complementarias sobre la calidad del buscador vectorial.

Precision@k

"De los peces que sacaste en la red, ¿cuántos eran los que buscabas?"

Mide la proporción de documentos **relevantes** entre los k recuperados. Una Precision@k baja significa que el contexto enviado al LLM está **contaminado** con ruido, lo que puede confundir la generación.

Recall@k

"De todos los peces buenos del lago, ¿qué porcentaje lograste atrapar?"

Mide cuántos documentos relevantes **existentes** fueron efectivamente recuperados. Un Recall@k bajo implica que información crítica fue **omitida**, dejando al LLM ciego ante datos clave.

📄 **Ejemplo con k=3:** Si hay 5 documentos relevantes en el corpus y el sistema recupera 3, de los cuales 2 son relevantes → **Precision@3 = $2/3 \approx 0,67$** y **Recall@3 = $2/5 = 0,40$** . Siempre existe una tensión entre ambas métricas.

MRR — El Impacto del Primer Flechazo

Mean Reciprocal Rank (MRR) evalúa una única pregunta: ¿en qué posición aparece el **primer** documento relevante? No le interesa el conjunto completo, solo la velocidad del acierto inicial.

La Fórmula

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$$

Donde **rank_i** es la posición del primer documento relevante para la consulta *i*. Se promedia sobre todas las consultas del conjunto de evaluación.

¿Cómo premia y castiga?

- **Posición 1** → Puntuación = 1,00 (máximo)
- **Posición 2** → Puntuación = 0,50
- **Posición 3** → Puntuación = 0,33
- **Posición 5** → Puntuación = 0,20 (severo castigo)

El descenso es **no lineal**: pasar del puesto 1 al 2 es mucho más costoso que pasar del 4 al 5.



Ideal para **asistentes de respuesta rápida** donde el usuario no quiere revisar múltiples resultados.

NDCG — El Valor del Orden

Normalized Discounted Cumulative Gain es la métrica más sofisticada del Retrieval. No solo pregunta si los documentos son relevantes, sino si están ordenados **de mayor a menor importancia**.



Nivel 1 — Relevancia Graduada

Los documentos no son simplemente "buenos" o "malos". Se les asignan **notas** (p. ej., 0 = irrelevante, 1 = parcialmente relevante, 2 = muy relevante). Esto captura la riqueza real del corpus.

1 —
2 —


Nivel 2 — Penalización por Posición

La información más crucial debe aparecer **arriba**. NDCG descuenta logarítmicamente la relevancia de los documentos según su posición: un documento muy relevante en la posición 5 vale mucho menos que en la posición 1.

310

Nivel 3 — Comparación contra el Orden Perfecto (IDCG)

El resultado se **normaliza** dividiéndolo entre el DCG ideal (IDCG), es decir, el ranking perfecto teórico. El valor final oscila entre 0 y 1: cuanto más cerca de 1, más se acerca el sistema al orden óptimo posible.




MÓDULO II

La Mente de la IA

Cómo evaluar si el LLM procesa... o inventa

El Dilema de la Factualidad — El Polígrafo del RAG



El LLM puede sonar brillante... y estar mintiendo.

¿Qué mide Faithfulness?

Faithfulness (Fidelidad) evalúa si cada afirmación presente en la respuesta generada puede ser **verificada directamente** en los documentos recuperados. Es el polígrafo del sistema RAG.

El riesgo oculto

Un LLM puede construir respuestas **elocuentes, bien estructuradas y con tono profesional** mientras introduce datos falsos, fechas incorrectas o cifras inventadas. La fluidez lingüística no garantiza la veracidad factual.



En entornos legales, médicos o financieros, una sola alucinación no detectada puede tener consecuencias graves. Faithfulness debe ser métrica prioritaria.

Dimensiones de la Respuesta — Relevancia y Concisión

Más allá de la factuality, una respuesta de calidad debe ser **pertinente** (contestar lo que se preguntó) y **eficiente** (sin redundancias que encarezcan el sistema). Dos patologías frecuentes lo rompen:

El que se va por las ramas

Baja Relevancia de Respuesta

El sistema genera una respuesta extensa y bien redactada, pero que **no responde la duda concreta del usuario**. El contexto recuperado puede ser correcto, pero el LLM divaga hacia información adyacente. Se mide comparando la pregunta original con el contenido real de la respuesta.

El redundante

Baja Concisión

La respuesta repite la misma idea con distintas palabras, **consumiendo tokens innecesariamente**. En sistemas con alto volumen de consultas, la baja concisión se traduce directamente en mayor coste operativo. La concisión se evalúa detectando proposiciones duplicadas dentro de la respuesta.

 Una respuesta ideal puntúa alto en **ambas dimensiones**: va al grano (alta relevancia) y no se repite (alta concisión). Optimizar solo una puede degradar la otra.

La Batalla Semántica: BLEU/ROUGE vs. BERTScore

El mismo contenido puede recibir puntuaciones radicalmente distintas según la métrica elegida. El siguiente contraejemplo lo ilustra con claridad:



Referencia humana

*"El comité **aprobó** el **presupuesto** municipal."*



Respuesta del sistema

*"La junta **autorizó** el **dinero** del ayuntamiento."*



BLEU / ROUGE — Conteo de Palabras

Miden la **coincidencia literal** de n-gramas entre referencia y respuesta generada. Al no compartir casi ninguna palabra exacta, asignan una puntuación **muy baja**... aunque el significado sea idéntico. Son rápidas y deterministas, pero **ciegas al significado**.



BERTScore — Embeddings Semánticos

Convierte cada token en un vector de significado y calcula la **similitud coseno** entre ambas frases. Detecta que "aprobó" $\approx$ "autorizó" y "presupuesto" $\approx$ "dinero", otorgando una puntuación **alta y correcta**. Es la opción robusta para lenguaje natural diverso.

La Clave del Éxito: El Golden Dataset

Ninguna métrica funciona si no existe primero un patrón de medida fiable. El Golden Dataset es ese patrón: un conjunto de prueba curado completamente a mano que actúa como el metro de platino del sistema RAG.



Preguntas Reales

Formuladas por usuarios reales o expertos del dominio. No preguntas artificiales ni demasiado simples. Deben cubrir casos límite, ambigüedades y variedad de formulaciones.



Documentos Verdaderos

Los fragmentos del corpus que realmente contienen la respuesta correcta. Etiquetados manualmente por expertos, no por el propio sistema. Son el suelo de referencia (ground truth) del Retrieval.



Respuestas de Referencia

Respuestas ideales redactadas por personas, no por la IA. Son el estándar contra el que se compara la generación. Sin ellas, métricas como Faithfulness o BERTScore no tienen ancla de comparación.

 Invertir tiempo en construir un Golden Dataset de calidad **multiplica el valor de todas las métricas** posteriores. Sin él, se mide con una regla torcida.

¿Cómo Elegir tu Métrica Clave?

No todas las métricas son igual de relevantes para todos los sistemas. Tu elección debe depender del **objetivo prioritario** de tu aplicación RAG.

Priorizo la velocidad de respuesta

Métrica estrella: MRR

Si el usuario necesita la respuesta correcta en el primer intento (chatbots, asistentes de soporte), MRR es tu indicador de cabecera. Un MRR cercano a 1 garantiza que el primer documento recuperado ya es el relevante.

Priorizo la precisión legal o médica

Métricas estrella: Faithfulness + NDCG

En entornos de alto riesgo, necesitas saber que el sistema no alucina (Faithfulness) y que los documentos más relevantes aparecen primero (NDCG). La combinación de ambas cubre integridad factual y calidad de ranking.

Priorizo el ahorro de costes en tokens

Métricas estrella: Concisión + Precision@k

Reducir tokens redundantes en la respuesta (Concisión) y evitar documentos irrelevantes en el contexto (Precision@k) disminuye directamente el coste por consulta en APIs de LLMs como GPT-4 o Claude.

Resumen ejecutivo del módulo

- Retrieval: Precision@k, Recall@k, MRR, NDCG
- Generation: Faithfulness, Relevancia, Concisión, BERTScore
- Fundamento: Golden Dataset bien curado

Espacio para Q&A

¿Qué métrica resulta más difícil de implementar en vuestro contexto?
¿Habéis encontrado tensiones entre Precision y Recall en vuestros sistemas? ¿Cómo gestionáis la construcción del Golden Dataset en producción?