

DIPLOMATURA EN INTELIGENCIA ARTIFICIAL · UBA

Planificación del Trabajo Final

Clase 1 – Repaso – Definiciones – Canvas

Profesor: Esp. Ing. Cristian Salinas Talamilla

Email: salinastalamilla@gmail.com

Lnk: <https://www.linkedin.com/in/cristian-patricio-salinas-talamilla-255b562a/>

Agenda de hoy

01

Introducción a la IA y los LLMs

Base teórica para entender los proyectos del grupo.

03

Definir un buen problema de IA

Errores comunes y herramientas para evitarlos.

05

Ronda de presentaciones

3 min por alumno para presentar la idea y recibir feedback.

02

Los tracks o enfoques

RAG y Clasificación/Agentes: qué son y cuándo aplicar cada uno.

04

AI Canvas simplificado

La herramienta para formalizar cada proyecto.

06

Ficha de Proyecto

Entregable del día.

¿Qué es la Inteligencia Artificial?

Base conceptual para entender los proyectos del grupo

Definición

Sistemas que realizan tareas asociadas a la inteligencia humana.

Qué hace

Reconoce patrones, aprende de datos y apoya decisiones.

En este curso

La usamos como base para proyectos de RAG, clasificación y agentes.

¿Cómo aprende una máquina?

01

Datos

Ejemplos etiquetados o no.

02

Entrenamiento

El algoritmo detecta patrones y ajusta parámetros.

03

Modelo

Función capaz de hacer predicciones.

04

Evaluación


Se mide el desempeño con datos nuevos.

05

Inferencia

Se usa en producción para resolver casos reales.

En los proyectos del grupo, el entrenamiento ya ocurrió: los LLMs como GPT, Llama y Gemini fueron entrenados con grandes volúmenes de texto. Nuestro trabajo es usarlos con criterio para cada problema específico.




<https://www.datacamp.com/blog/top-machine-learning-use-cases-and-algorithms>

https://s3.amazonaws.com/assets.datacamp.com/email/other/ML+Cheat+Sheet_2.pdf

datacamp Top Machine Learning Algorithms

		ALGORITHM	DESCRIPTION	APPLICATIONS	ADVANTAGES	DISADVANTAGES
> Supervised Learning	Linear Models	Linear Regression	A simple algorithm that models a linear relationship between inputs and a continuous numerical output variable	USE CASES 1. Stock price prediction 2. Predicting housing prices 3. Predicting customer lifetime value	1. Explainable method 2. Interpretable results by its output coefficients 3. Faster to train than other machine learning models	1. Assumes linearity between inputs and output 2. Sensitive to outliers 3. Can underfit with small, high-dimensional data
		Logistic Regression	A simple algorithm that models a linear relationship between inputs and a categorical output (1 or 0)	USE CASES 1. Credit risk score prediction 2. Customer churn prediction	1. Interpretable and explainable 2. Less prone to overfitting when using regularization 3. Applicable for multi-class predictions	1. Assumes linearity between inputs and outputs 2. Can overfit with small, high-dimensional data
		Ridge Regression	Part of the regression family — it penalizes features that have low predictive outcomes by shrinking their coefficients closer to zero. Can be used for classification or regression	USE CASES 1. Predictive maintenance for automobiles 2. Sales revenue prediction	1. Less prone to overfitting 2. Best suited where data suffer from multicollinearity 3. Explainable & interpretable	1. All the predictors are kept in the final model 2. Doesn't perform feature selection
		Lasso Regression	Part of the regression family — it penalizes features that have low predictive outcomes by shrinking their coefficients to zero. Can be used for classification or regression	USE CASES 1. Predicting housing prices 2. Predicting clinical outcomes based on health data	1. Less prone to overfitting 2. Can handle high-dimensional data 3. No need for feature selection	1. Can lead to poor interpretability as it can keep highly correlated variables
	Tree-Based Models	Decision Tree	Decision Tree models make decision rules on the features to produce predictions. It can be used for classification or regression	USE CASES 1. Customer churn prediction 2. Credit score modeling 3. Disease prediction	1. Explainable and interpretable 2. Can handle missing values	1. Prone to overfitting 2. Sensitive to outliers
		Random Forests	An ensemble learning method that combines the output of multiple decision trees	USE CASES 1. Credit score modeling 2. Predicting housing prices	1. Reduces overfitting 2. Higher accuracy compared to other models	1. Training complexity can be high 2. Not very interpretable
		Gradient Boosting Regression	Gradient Boosting Regression employs boosting to make predictive models from an ensemble of weak predictive learners	USE CASES 1. Predicting car emissions 2. Predicting ride hailing fare amount	1. Better accuracy compared to other regression models 2. It can handle multicollinearity 3. It can handle non-linear relationships	1. Sensitive to outliers and can therefore cause overfitting 2. Computationally expensive and has high complexity
		XGBoost	Gradient Boosting algorithm that is efficient & flexible. Can be used for both classification and regression tasks	USE CASES 1. Churn prediction 2. Claims processing in insurance	1. Provides accurate results 2. Captures non linear relationships	1. Hyperparameter tuning can be complex 2. Does not perform well on sparse datasets
		LightGBM Regressor	A gradient boosting framework that is designed to be more efficient than other implementations	USE CASES 1. Predicting flight time for airlines 2. Predicting cholesterol levels based on health data 3. Low memory usage	1. Can handle large amounts of data 2. Computational efficient & fast training speed 3. Low memory usage	1. Can overfit due to leaf-wise splitting and high sensitivity 2. Hyperparameter tuning can be complex
> Unsupervised Learning	Clustering	K-Means	K-Means is the most widely used clustering approach—it determines K clusters based on euclidean distances	USE CASES 1. Customer segmentation 2. Recommendation systems	1. Scales to large datasets 2. Simple to implement and interpret 3. Results in tight clusters	1. Requires the expected number of clusters from the beginning 2. Has troubles with varying cluster sizes and densities
		Hierarchical Clustering	A "bottom-up" approach where each data point is treated as its own cluster—and then the closest two clusters are merged together iteratively	USE CASES 1. Fraud detection 2. Document clustering based on similarity	1. There is no need to specify the number of clusters 2. The resulting dendrogram is informative	1. Doesn't always result in the best clustering 2. Not suitable for large datasets due to high complexity
		Gaussian Mixture Models	A probabilistic model for modeling normally distributed clusters within a dataset	USE CASES 1. Customer segmentation 2. Recommendation systems	1. Computes a probability for an observation belonging to a cluster 2. Can identify overlapping clusters 3. More accurate results compared to K-means	1. Requires complex tuning 2. Requires setting the number of expected mixture components or clusters
	Association	Apriori algorithm	Rule based approach that identifies the most frequent itemset in a given dataset where prior knowledge of frequent itemset properties is used	USE CASES 1. Product placements 2. Recommendation engines 3. Promotion optimization	1. Results are intuitive and Interpretable 2. Exhaustive approach as it finds all rules based on the confidence and support	1. Generates many uninteresting itemsets 2. Computationally and memory intensive. 3. Results in many overlapping item sets

Hitos clave de la IA



¿Cuándo usar IA y cuándo no?

✓ Bueno para IA

- Demasiadas reglas para programar manualmente.
- Hay patrones, pero no una regla clara.
- Se trabaja con texto, imágenes o datos complejos.
- Hay datos suficientes para aprender.
- Una respuesta aproximada es útil.

× No usar IA cuando...

- La regla es simple y se puede codificar.
- No hay datos, o son insuficientes.
- Un error no es aceptable.
- La transparencia total es obligatoria.
- La solución más simple ya funciona.

Del texto a la inteligencia

Natural Language Processing y Large Language Models

Procesar

Convertir lenguaje humano en señales útiles para sistemas.

Entender

Detectar intención, contexto y significado en texto.

Generar

Responder, resumir y crear contenido con modelos de lenguaje.

¿Qué es el NLP?

Rama de la IA que permite entender, interpretar y generar lenguaje humano.



Clasificación

- ¿Positivo o negativo?
- ¿Spam o no spam?



Búsqueda semántica

- Encuentra textos similares
- Según el significado



NER (Reconocimiento de Entidades Nombradas)

- Identifica entidades
- Personas, lugares y fechas



Generación

- Respuestas y resúmenes
- Traducción y Q&A

¿Qué es un Large Language Model (LLM),?

Modelo de deep learning entrenado con grandes volúmenes de texto para predecir y generar lenguaje.

No “entiende” como humano: estima la siguiente palabra más probable según el contexto.



GPT-4 / ChatGPT

OpenAI. Propietario.
Muy capaz, de pago.



LLaMA / Ollama

Meta. Open source.
Corre en hardware local.



Gemini

Google. Multimodal.
Integrado en Workspace.



Claude

Anthropic.
Más enfoque en seguridad y razonamiento.

¿Cómo funciona un LLM? (conceptual)

Analogía: un autocompletado muy sofisticado.

1. **Tokenización:** divide el texto en tokens. Ej.: "inteligencia artificial" = 3 tokens.
2. **Embeddings:** convierte cada token en un vector que captura su significado.
3. **Atención:** detecta qué tokens se relacionan más para entender el contexto.
4. **Generación:** predice el siguiente token, uno a uno, hasta formar la respuesta.

Tokens y ventana de contexto

Qué procesa un LLM y cuánto puede leer a la vez.

Token

Unidad mínima de texto que procesa el modelo.

Regla rápida

≈ 1 token = ¾ palabra en inglés o 1 palabra en español.

Ejemplo visual de tokenización


Texto: "¿Cómo estás hoy?"

¿Cómo 1234	estás 5678	hoy 9012	? 3456
---------------	---------------	-------------	-----------

Tokens: ["¿Cómo", " estás", " hoy", "?"]

Token IDs: [1234, 5678, 9012, 3456]

Comparación de tokenización



Comparación de tokenización y ventana de contexto

Comparación de tokenización

Muestra cómo diferentes tipos de texto se dividen diferente:

Palabra común

"inteligencia" = 1 token

Palabra rara

"xyzabc" = 3-4 tokens

Número

"2024" = 1 token

Emoji

"😊" = 1-2 tokens

Código

"def function()" = 4-5 tokens

Conclusión: Las palabras comunes son eficientes, las raras consumen más tokens.

Ventana de contexto

La cantidad máxima de tokens que el modelo puede procesar en una consulta.

Ejemplos por modelo:

- GPT-3.5: 4,096 tokens
- GPT-4: 32768 tk
- Claude 3: 100,000 tokens
- Llama 2: 4,096 tokens

Implicación para RAG: Cuanto mayor la ventana, más documentos puedes inyectar en una consulta.

Limitaciones de los LLMs

Clave para evaluar riesgos en el Trabajo Final.

Alucinaciones

Puede inventar datos con total seguridad.

Fecha de corte

Solo conoce lo aprendido hasta su entrenamiento.

Sin memoria por defecto

No recuerda conversaciones anteriores sin historial.

Sesgo del entrenamiento

Hereda sesgos presentes en los datos de origen.

No razona, predice

Genera la respuesta más probable, no "piensa".

Alucinaciones: el problema central

Un LLM puede inventar hechos, citas, leyes o procedimientos con total confianza.

¿Por qué ocurre?

- Optimiza coherencia, no verdad.
- No tiene datos en tiempo real ni acceso a documentos específicos.
- No sabe cuándo no sabe algo.

¿Cómo lo mitiga RAG?

- Entrega al LLM el documento correcto como contexto.
- Reduce la invención al anclar la respuesta en fuentes concretas.
- Base técnica de los proyectos del Track A.

RAG no elimina el riesgo, pero lo reduce al obligar al modelo a responder con evidencia.

Ingeniería de prompts

La forma del prompt define la calidad de la respuesta del LLM.

Ser específico

- Define formato, tono y extensión
- Reduce ambigüedad

Dar contexto

- Rol del modelo
- Perfil del usuario o caso de uso

Ejemplos (few-shot)

- Muestra el formato esperado
- Mejora consistencia y estilo

Chain-of-thought

- Pide razonamiento paso a paso
- Útil en problemas complejos

 Ejemplos: "Respondé en español, en menos de 3 párrafos, como para un principiante." / "Sos un asesor de nutrición animal y el usuario es un productor de carne vacuna."

LLMs en industria — casos reales

Aplicaciones concretas por sector:

-  **Salud**
 - Responde preguntas con documentación médica oficial
-  **Finanzas**
 - Clasifica incidentes, detecta anomalías y resume reportes
-  **Agro**
 - Asesora sobre nutrición, sanidad y manejo
-  **Legal**
 - Búsqueda semántica en jurisprudencia y contratos
-  **Educación**
 - Adapta explicaciones al nivel del estudiante y corrige ejercicios
-  **Medios**
 - Detecta sesgo editorial y clasifica contenido automáticamente

¿Qué es RAG?

Retrieval Augmented Generation

- Búsqueda semántica + generación de texto.
- Inyecta el documento correcto antes de responder.
- Reduce la dependencia de la memoria del LLM.

-
1. Pregunta del usuario
 2. Búsqueda en documentos
 3. Recuperación de chunks relevantes
 4. Respuesta del LLM basada en evidencia
 5. Salida fundamentada y sin alucinaciones

Track A — Arquitectura RAG en detalle

Fase de indexación — se hace una sola vez

01

Documentos

PDF, web y texto

03

Embeddings

Vectorizar cada chunk

Fase de consulta — se ejecuta en cada pregunta

01

Pregunta

Consulta del usuario

03

Búsqueda top-k

Recuperar chunks relevantes

Herramientas principales

Frameworks

LangChain / LlamaIndex

Vector DB

ChromaDB / FAISS

Modelos

OpenAI / Ollama / Gemini

Embeddings

sentence-transformers

02

Chunking

Dividir en fragmentos

04

Vector Store

Guardar los vectores

02

Embedding

Vector de la pregunta

04

Respuesta

LLM responde con contexto

Track — Clasificación de texto

Asignar una o más etiquetas predefinidas a un fragmento de texto. Es una de las tareas más comunes y útiles de NLP.

Zero-shot

El LLM clasifica sin ejemplos previos.

Rápido de implementar, menos preciso.

Few-shot

Se le dan 2-5 ejemplos al LLM antes de clasificar.

Mejora notable en la precisión.

Fine-tuning

Se entrena un modelo sobre ejemplos propios.

Mayor precisión, mayor costo.

Track B — Agentes de IA

Un agente usa un LLM para razonar, actuar y completar tareas complejas de forma autónoma.

Loop ReAct (Reason + Act):

01

Observar

Recibe la tarea y el contexto actual.

03

Actuar

Ejecuta una acción: buscar, calcular, escribir o llamar API.

02

Razonar

Decide qué herramienta usar o qué paso dar.

04

Actualizar contexto

Incorpora el resultado y define el siguiente paso.

Track B — Casos de uso en el grupo

Aplicaciones de agentes de IA desarrolladas por el grupo.

Clasificador de intenciones

- Clasifica el tipo de mensaje recibido
- Orienta al receptor sobre qué esperar
- *Tomás Caserez*

Detector de sesgo político

- Identifica sesgo editorial en noticias
- Analiza contenido scrapeado de distintos medios
- *Diego Methol*

Análisis de sentimiento YouTube

- Clasifica comentarios de usuarios
- Pronostica comportamiento en redes sociales
- *Shimon Bentancur*

Helpdesk automatizado

- Clasifica y enruta incidentes técnicos
- Enfocado en empresa de lotería/gaming
- *Jose Zebraitis*

A definir

- NLP/LLMs con dataset propio
- Track en definición
- *Mariana García*

PASO 1

Definir el problema

Antes de escribir código, aclara qué se quiere resolver

- Qué necesita el usuario
- Qué decisión o respuesta debe generar el sistema
- Qué está dentro y fuera del alcance

Errores comunes al definir el problema

Evita estos cinco bloqueos antes de avanzar:

- **Demasiado amplio:** mejor un caso de uso concreto.
- **Datos no disponibles:** verifica acceso, formato y calidad.
- **IA innecesaria:** si una regla simple basta no es necesario un sistema basado en IA.
- **Éxito ambiguo:** define métricas claras desde el inicio.
- **Usuario difuso:** concreta quién lo usará y qué necesita.

PoC, MVP y Producción — ¿qué tipo de trabajos es?



PoC

Proof of Concept

- Valida que la idea sea técnicamente posible
- Sin escala ni usuarios reales
- Solo prueba el concepto



MVP

Minimum Viable Product

- Primera versión usable
- Resuelve el problema principal
- Para un subconjunto de usuarios reales




Producción

Sistema en producción

- Escalable, mantenible y monitoreable
- Usuarios reales y SLAs
- Reentrenamiento periódico

Trabajo Final DIIA



¿Qué es el AI Canvas?

"Una ayuda para contemplar, construir y evaluar herramientas de IA."
— *Agrawal, Gans & Goldfarb, Prediction Machines (2018)*

Es un mapa

- Ordena la conversación antes de construir
- Ayuda a ver el proyecto completo

Alinea a todos

- Pone problema, dato y solución en la misma página
- Reduce ambigüedades desde el inicio

Fuerza decisiones tempranas

- Obliga a definir supuestos clave
- Si no se puede completar, el problema aún no está listo

5 preguntas para definir tu proyecto RAG en clase, ahora.

1

¿Qué problema resuelvo?

- Una oración.
- Sin mencionar tecnología.
- Enfocado en el usuario.

2

¿Para quién?

- Persona, equipo o empresa.
- Usuario final que consulta.
- ¿Qué saben? ¿Qué necesitan?

3

¿Con qué documento trabajo?

- ¿Qué corpus de texto usa el sistema?
- ¿Dónde está y qué tan accesible es?
- ¿Está estructurado o no?

4

¿Qué tipo de RAG construyo?

- Track A: Naive RAG / RAG básico.
- Track B: RAG avanzado / Agentic.
- Elegí según el corpus y el caso.

5

¿Cómo voy a saber si funciona?

- Una métrica RAG (faithfulness, answer relevance, context recall).
- Una evaluación cualitativa: ¿responde bien preguntas reales?
- Una pregunta de golden-set que el sistema debe responder correctamente.

RAG PROJECT CANVAS

Título del Proyecto: _____

CORPUS / DATOS

¿Qué documentos o fuentes de texto indexa el RAG? (PDFs, webs, DBs, APIs)

MODELO LLM

¿Qué LLM genera las respuestas? (GPT-4, Claude, Llama...)

EMBEDDINGS & RETRIEVAL

¿Qué modelo de embeddings? ¿Qué vector store? (FAISS, Pinecone, Chroma...)

PROPUESTA DE VALOR

¿Qué valor añade la búsqueda semántica sobre documentos propios? ¿Por qué RAG y no fine-tuning?

INTEGRACIÓN

¿Cómo se conecta a sistemas existentes? (API, plugin, chat UI...)

STAKEHOLDERS

¿Quiénes son los interesados? (sponsor, equipo, soporte)

USUARIOS FINALES

¿Quiénes consultan el sistema? ¿Cuál es su perfil técnico?

COSTOS


Indexación (embeddings batch), almacenamiento vectorial, tokens LLM por consulta, hosting, mantenimiento del corpus.

MÉTRICAS RAG

Faithfulness · Answer Relevance · Context Recall · Latencia por consulta · Tasa de hallucination

VALOR / INGRESOS


¿Cómo genera valor económico? (ahorro soporte, licencias, productividad)



CORPUS / DATOS Manual del empleado, políticas de vacaciones y licencias, reglamento interno, convenios colectivos, formularios descargables. ~200 documentos PDF. Actualización mensual.	MODELO LLM Llama 3.1 8B (self-hosted, Ollama). 100% on-premise por confidencialidad. Temperatura 0 para respuestas deterministas sobre políticas. EMBEDDINGS & RETRIEVAL omic-embed-text (local). Vector store: ChromaDB (local). Chunking: por sección de documento. Top-K: 3 fragmentos. Pipeline: LangChain.	PROPUESTA DE VALOR Empleados obtienen respuestas a preguntas de RRHH en segundos, sin email. RRHH libera 10h/semana de consultas repetitivas. 100% privacidad de datos.	INTEGRACIÓN Chatbot en Slack (app bot). Acceso web interno (intranet). Sin conexión a internet. Datos nunca salen del servidor de la empresa. STAKEHOLDERS Sponsor: Director RRHH. IT: aprueba infraestructura on-premise. Legal: revisa políticas indexadas. Empleados: usuarios finales.	USUARIOS FINALES Todos los empleados de la empresa (~800 personas). Perfil: no técnico. Preguntas típicas: '¿Cuántos días de vacaciones tengo?' '¿Cómo pido licencia?'
COSTOS Servidor local: \$0 adicional (usa infra existente). Ollama + Llama: gratis (open source). ChromaDB: gratis. Mantenimiento corpus: 4h/mes del equipo RRHH.		MÉTRICAS RAG Answer Relevance > 0.85. Reducción de emails a RRHH en 40% (medición mensual). Feedback binario de usuario (👍/👎) por respuesta. Cobertura de temas > 90%.		VALOR / INGRESOS Ahorro de 10h/sem del equipo RRHH → \$18K/año. Mejora de experiencia del empleado (encuesta eNPS). Escalable a otras áreas (Legal, Compras).

Canvas para RAG — Arquitectura y Decisiones

Un canvas especializado para proyectos Track A (RAG/Chatbot). Incluye 6 secciones clave:



1. Fuentes de datos

¿De dónde vienen los documentos? (PDFs, web, bases de datos, APIs)

2. Estrategia de chunking

¿Cómo divides los documentos? (tamaño, solapamiento, estrategia)

3. Embeddings y búsqueda

¿Qué modelo de embeddings? ¿Qué vector database? (Qdrant, Pinecone, Weaviate)

4. Contexto y prompt

¿Cómo armas el contexto? ¿Cuántos documentos? ¿Qué instrucciones al LLM?

5. LLM elegido

¿Qué modelo? (GPT-4, Claude, Llama, Gemini) ¿Parámetros de temperatura y tokens?

6. Evaluación

¿Cómo mides calidad? (RAGAS, evaluación manual, métricas de relevancia)

Dinámica de hoy

Ronda de presentaciones

Canvas template

Ronda de presentaciones

Cada alumno tiene 3 minutos para explicar

01

Problema

¿Qué querés resolver?

⚠ Dato inexistente o inaccesible

03

Datos

¿Qué dato tenés o de dónde lo obtenés?

⚠ Problema mal definido

ćċ

Usuario

¿Para quién es la solución?

⚠ Alcance demasiado ambicioso

ćċ

IA

¿Cómo lo resolverías con IA?

✓ Track claro (A o B)

 **Uso concreto y acotado**

Entregable de esta clase

Ficha de Proyecto

1. Problema en una oración
2. Dataset identificado o estrategia para obtenerlo
3. Track declarado (NLP Clasico, RAG, Agentes) + justificación breve
4. Canvas completo