

Clase 2 · EDA y Visualización

Análisis Exploratorio + Reglas de visualización + Tu proyecto

Boletín Oficial Salta · seaborn / matplotlib · datos reales

Teoría → Ejemplo práctico → Tu proyecto

Agenda de hoy

01

Teoria

Que es EDA. La regla de oro. Tipos de variables.

15MIN

03

Ejemplo practico

Aplicamos las 8 reglas al Boletin Oficial Salta N 21.922 con datos reales.

15MIN

02

Reglas de visualizacion

Tabla de decision: que grafico para que tipo de dato. 8 reglas con ejemplos.

20MIN

04


Tu proyecto

Cada uno aplica el EDA a su propio dataset. Ronda de presentacion.

25MIN

Parte I · Teoria

Que es EDA y por que hacerlo antes de modelar



EDA, o Exploratory Data Analysis, es el proceso de explorar y resumir un dataset para entender su estructura y calidad antes de modelar. Es esencial porque permite detectar patrones, tendencias y anomalías desde el inicio, evitando errores y decisiones basadas en supuestos incorrectos.

Tambien ayuda a identificar problemas como valores faltantes, outliers, variables mal codificadas, distribuciones sesgadas y relaciones inesperadas entre variables.

La regla de oro del EDA

 EDA es el proceso de examinar los datos ANTES de modelar. No se trata de confirmar hipótesis, sino de descubrir la estructura real, las anomalías y las relaciones que existen en los datos.

01

Mira ANTES de modelar

El 80% de los problemas del modelo se detectan en el EDA.
Un gráfico vale más que mil supuestos.

03

Cuestiona lo obvio

Los datos gubernamentales tienen errores reales. 'Este dato no tiene sentido' es una hipótesis válida.

02

Documenta cada hallazgo

Cada gráfico necesita 1 oración debajo explicando que encontraste y que implica para el modelo.

04

Baseline antes de modelo complejo

El baseline mide el punto cero. Sin baseline no sabes si tu modelo agrega valor.

Tipos de variables: la base para elegir el grafico

Numerica continua

Ej: Precio, edad, longitud de texto, IPC

Numerica discreta

Ej: Cantidad de articulos, palabras por documento

Categorica nominal

Ej: Tipo de documento, ministerio, especie

Categorica ordinal

Ej: Clase del barco (1a/2a/3a), nivel de severidad

Binaria

Ej: Sobrevivio / no sobrevivio * activo / inactivo

Texto libre

Ej: Contenido del decreto, transcripcion, comentario

Antes de cada grafico: identifica el tipo de cada variable involucrada.

Ejemplo de Dataset: Todos los Tipos de Variables

Para consolidar la comprensión de los tipos de variables, a continuación se presenta un ejemplo de una fila de datos que incluye cada uno de los tipos:

Numerica Continua	Numerica Discreta	Categorica Nominal	Categorica Ordinal	Binaria	Texto Libre
150.75	3	Producto	Alto	Si	Descripción detallada del producto con características únicas y componentes innovadores.

Este ejemplo demuestra cómo una misma entrada de datos puede contener diferentes formatos, cada uno requiriendo un enfoque específico para su análisis y visualización.

	id_viaje	fecha_salida	prioridad	tipo_vehiculo	distancia_km	paquetes_entregados	entrega_exitosa	consumo_combustible	coordenadas_destino	comentarios_chofer
0	TRIP-000	2026-01-14	Alta	Camión	246.17	16	True	24.64	(-24.1576, -64.9575)	Clima adverso
1	TRIP-001	2026-01-10	Alta	Furgón	116.34	44	True	19.08	(-24.8317, -65.3903)	Dirección incorrecta
2	TRIP-002	2026-01-15	Baja	Furgón	235.23	3	True	19.38	(-24.9632, -64.6588)	Dirección incorrecta
3	TRIP-003	2026-03-27	Alta	Camión	302.75	42	True	16.70	(-24.7857, -65.3714)	Dirección incorrecta
4	TRIP-004	2026-01-31	Alta	Moto	233.25	6	True	15.20	(-24.867, -64.6699)	Dirección incorrecta

Parte II · Reglas de visualización

Qué gráfico para que tipo de dato

Importancia

Elegir el gráfico correcto es clave para comunicar ideas con claridad. Una visualización equivocada puede ocultar patrones importantes, exagerar diferencias o incluso llevar a interpretaciones erróneas. En cambio, el gráfico adecuado permite identificar tendencias, comparaciones y relaciones casi de inmediato, haciendo que el mensaje sea más fácil de entender y más convincente.

Consejos prácticos

Para usar bien la tabla de decisión, comienza identificando el tipo de variables que tienes: numéricas, categóricas, temporales o mixtas. Después, busca en la tabla la combinación que mejor encaja con tus datos y, sobre todo, piensa en la pregunta que quieres responder. No es lo mismo querer comparar categorías, mostrar una evolución en el tiempo o analizar una relación entre variables; la intención de análisis debe guiar la elección del gráfico.

8 reglas

A continuación se presentan 8 reglas de visualización que te ayudarán a tomar mejores decisiones. Cada regla mostrará un escenario específico, acompañado de ejemplos de código y buenas prácticas para aplicarlo correctamente en casos reales.





Tabla de decision: el grafico correcto

Esta tabla resume qué visualización conviene usar según el tipo de datos y la combinación de variables que tengas. Cada gráfico está pensado para responder preguntas distintas, así que sirve como guía rápida para elegir la opción más adecuada según la situación que quieres analizar.

Úsala como referencia práctica: identifica si tus variables son numéricas, categóricas o mixtas, y luego elige el gráfico que mejor se adapte a la pregunta que quieres responder.

Situacion	Grafico	Codigo seaborn
1 Numerica	Histograma + KDE	<code>sns.histplot(kde=True)</code>
1 Categorica	Barras horizontales	<code>sns.countplot()</code> / <code>ax.barh()</code>
Numerica x Numerica	Scatter plot	<code>sns.scatterplot()</code> / <code>sns.regplot()</code>
Numerica x Categorica	Boxplot + Stripplot	<code>sns.boxplot()</code> + <code>sns.stripplot()</code>
Categorica x Categorica	Heatmap de conteos	<code>pd.crosstab()</code> + <code>sns.heatmap()</code>
Comparar distribuciones	KDE superpuestas / ECDF	<code>sns.kdeplot(hue=...)</code>
Muchas variables numericas	Heatmap correlacion	<code>df.corr()</code> + <code>sns.heatmap()</code>
Vista exploratoria general	Pairplot	<code>sns.pairplot(hue=...)</code>
Texto / NLP	Barras de frecuencia	<code>Counter()</code> + <code>ax.barh()</code>

Regla 1 · Una variable numerica: Histograma + KDE

❗ Usa SIEMPRE las dos capas: histograma (exacto) + KDE (suavizado). Un histograma solo puede enganar si bins esta mal elegido.



```
sns.histplot(df['palabras'],
             bins=30, kde=True, color='teal')

# Lineas de tendencia central
plt.axvline(df['palabras'].median(),
            color='tomato', linestyle='--',
            label='Mediana')
plt.axvline(df['palabras'].mean(),
            color='navy', linestyle='--',
            label='Media')
```

Para comparar grupos:

```
sns.kdeplot(grupo_A, fill=True, alpha=0.35)
sns.kdeplot(grupo_B, fill=True, alpha=0.35)
```

⚠ Evitar: histograma solo sin KDE. El numero de bins cambia la forma percibida.



CATEGORICA

Regla 2 · Una variable categorica: Barras

```
# Siempre ordenar de mayor a menor
conteo = df['tipo'].value_counts()
        .sort_values()

# Horizontal si las etiquetas son largas
ax.barh(conteo.index, conteo.values,
        color=colores, alpha=0.85)

# Agregar valores al costado
for bar, val in zip(ax.patches, valores):
    ax.text(val+0.3,
            bar.get_y()+bar.get_height()/2,
            str(val), va='center',
            fontweight='bold')
```

+ Barras horizontales

Etiquetas largas o muchas categorías

+ Countplot vertical

Pocas categorías con etiquetas cortas


x Pie chart

Solo 2-3 categorías. Evitar siempre si es posible.


x Barplot de medias

Nunca: oculta la distribución completa.

OPs por tipo de documento
(Boletín Oficial Salta N° 21.922)



Tickets por día
(countplot vertical — pocos grupos)



NUM X NUM

Regla 3 · Numerica x Numerica: Scatter plot

```
# Basico con correlacion
ax.scatter(df['x'], df['y'],
          alpha=0.5, edgecolors='white', s=50)
r = df[['x', 'y']].corr().iloc[0,1]
ax.text(0.05, 0.92, f'r = {r:.2f}',
       transform=ax.transAxes, fontsize=13)

# Con color por grupo + regresion
for grupo, color in grupos.items():
    mask = df['tipo'] == grupo
    ax.scatter(df[mask]['x'], df[mask]['y'],
              color=color, label=grupo, alpha=0.6)
sns.regplot(data=df, x='x', y='y',
            scatter=False, linestyle='--')
```

$r < 0.3$

Correlacion debil

0.3–0.7



Correlacion moderada

$r > 0.7$




Correlacion fuerte

$N > 5.000$

Usar hexbin (overplotting)



Regla 4 · Numerica x Categorical: Boxplot



```
# La combinacion ideal: estructura + puntos
sns.boxplot(data=df, x='tipo', y='palabras',
            palette=colores, showfliers=False, width=0.5)
sns.stripplot(data=df, x='tipo', y='palabras',
              color='black', alpha=0.3, size=3, jitter=True)
ax.set_yscale('log') # cuando rango > 10x
```

boxplot

Primera exploracion

violinplot

Cuando la forma importa

stripplot

N < 100 (ver puntos)

Regla 5 ·

Categorica x Categorica:



Heatmap de conteos

```
# Paso 1: tabla de contingencia
ct = pd.crosstab(df['tipo'], df['seccion'])

# Paso 2: heatmap de conteos
sns.heatmap(ct, annot=True, fmt='d',
            cmap='YlOrRd', linewidths=0.5)

# Paso 3: normalizado por fila
ct_norm = ct.div(ct.sum(axis=1), axis=0)
sns.heatmap(ct_norm, annot=True,
            fmt='%.0%', cmap='Blues',
            vmin=0, vmax=1)
```

<code>annot=True</code>	Siempre activar — numero hace el grafico autoexplicativo
<code>fmt='d'</code>	Enteros. Usar '%.0%' para porcentajes
<code>cmap='RdBu_r'</code>	Diverging: para proporciones centradas en 50%
Mostrar ambos	Conteos Y proporciones dan perspectivas distintas



Regla 6 · Comparar distribuciones: KDE y ECDF

```
# KDE superpuestas – la mas facil de leer
for grupo, color in zip(grupos, colores):
    subset = df[df['grupo']==grupo]['valor']
    sns.kdeplot(subset, label=grupo,
                fill=True, alpha=0.35, linewidth=2)

# ECDF – sin bins, sin parametros
subset_sorted = subset.sort_values()
n = len(subset_sorted)
y_ecdf = np.arange(1, n+1) / n
ax.step(subset_sorted, y_ecdf,
        label=grupo, linewidth=2)
```

KDE



- + Visual, fácil de leer
- Bandwidth puede engañar

ECDF

- + Sin parámetros, leer cuartiles directo
- Menos intuitiva

Hist. apilados

- + Muestra conteos reales
- Difícil comparar grupos



Regla 7 · Muchas variables: Heatmap de correlacion

```
# Siempre con mascara del triangulo superior
corr = df[num_cols].corr()
mask = np.triu(np.ones_like(corr,
                             dtype=bool))

sns.heatmap(corr,
            mask=mask,      # triangulo inferior
            annot=True,
            fmt='.2f',
            cmap='RdBu_r',  # diverging
            center=0,       # 0 en el centro
            vmin=-1, vmax=1) # escala completa
```

`mask=np.triu(...)`

Oculta triangulo superior — sin este, la info se duplica

`cmap='RdBu_r'`



Rojo = negativa, Azul = positiva, Blanco = 0

`center=0`


Garantiza que 0 quede en color neutro

`vmin=-1, vmax=1`

Fuerza rango completo aunque datos no lleguen a extremos



Regla 7b · Pairplot: vista exploratoria completa



Que muestra el pairplot

- Diagonal: distribucion por variable
- Off-diagonal: scatter de cada par
- Color: separacion por clase
- De un vistazo: correlaciones + clusters



Codigo

```
sns.pairplot(  
    df, hue='clase',  
    diag_kind='hist',  
    plot_kws={'alpha':0.5,  
              's':30},  
    height=2.2  
)
```

Limitacion: ilegible con mas de 6-7 variables.

Regla 8 · Texto y NLP: frecuencias de términos

Hallazgo clave

Los vocabularios son muy distintos entre tipos de documento. Decreto vs. Sucesorio vs. Adjudicación tienen términos completamente diferentes. → Alta separabilidad semántica → TF-IDF + LR puede ser suficiente para Track B.



```
from collections import Counter
import re

STOP = {'de', 'la', 'el', 'en', 'y', 'a', 'los', 'se', ...}

def tokenizar(texto):
    texto = re.sub(r'^a-zaeiouun\s', ' ',
                  texto.lower())
    return [t for t in texto.split()
            if len(t)>3 and t not in STOP]

freq = Counter(tokenizar(texto))
top = freq.most_common(7)
ax.barh([t for t, _ in top][::-1],
        [v for _, v in top][::-1],
        color=color)
```


Top términos por tipo de documento — Boletín Oficial Salta




Errores mas comunes de visualizacion

Error común: pie chart → usar barras

❑ Pie chart con 6 categorías
(etiquetas se superponen, difícil comparar)



❑ Barras horizontales ordenadas
(fácil de leer y comparar)




Error común: barplot de medias → usar boxplot

❑ Barplot de medias
(oculta la distribución completa)



❑ Boxplot + Stripplot
(muestra estructura + puntos individuales)



Principios de diseño: graficos que comunican

1

Título = el hallazgo

Malo: 'Longitud' Bueno: 'Los decretos son 15x mas largos que los edictos'

2

Ejes con unidades

Malo: 'y' Bueno: 'Palabras por documento' o 'USD' o 'Tokens (BPE)'

3

Alpha para superposicion

Cuando los puntos se superponen: $\alpha=0.4$. Sin α : informacion oculta.

4

Un gráfico = un hallazgo

Si el grafico necesita 3 parrafos para explicarse, dividilo en dos.

5

Ordenar categorias

Siempre de mayor a menor. La posición importa para la lectura visual.

6

Grid suave


$\alpha=0.3$ en el grid. Fondo blanco limpio. Los spines top y right, apagados.

Parte III · Ejemplo práctico

Las 8 reglas aplicadas al Boletín Oficial Salta N 21.922

Panel EDA completo — Boletín Oficial Salta N° 21.922

Panel EDA — Boletín Oficial Salta N° 21.922



Hallazgos del EDA — lo que aprendimos de los datos

1 Distribucion muy asimetrica

Mediana 120 palabras, media 380. Skewness positivo. Escala log necesaria. Los decretos tiran la media hacia arriba.

2 Adjudicaciones + contrataciones dominan

65% del corpus. Son documentos cortos y repetitivos. Para RAG: aportan poco contexto. Para Track B: clase mayoritaria.

3 La longitud discrimina fuertemente

Decretos 1.200 palabras vs. adjudicaciones 90 palabras (ratio 13x). Un clasificador con solo esta feature ya tiene poder predictivo.

4 73% de OPs caben en 512 tokens

La mayoría de documentos no necesitan chunking. El retriever va a recuperar OPs completas en la mayoría de los casos.

5 Vocabularios muy distintos por tipo

Los terminos de decretos, sucesorios y adjudicaciones casi no se solapan. → TF-IDF + LR puede ser suficiente para Track B.

PARTE IV

Tu proyecto

Aplica las 8 reglas a tu propio dataset

Dinamica: EDA de tu proyecto — 25 minutos

```
# TEMPLATE — completar para cada visualización
# -----
# Variables:          [nombre y tipo: numerica / categorica / texto]
# Pregunta:           [que quieres saber?]
# Grafico elegido:     [histplot / boxplot / scatter / heatmap / etc.]
# Justificacion:       [por que ESTE grafico? consulta la tabla de decisión]

fig, ax = plt.subplots(figsize=(10, 5))
# sns.GRAFICO(data=tu_df, x='...', y='...', palette='Set2', ...)
# ax.set_title('Titulo = el HALLAZGO, no el nombre de la variable')
plt.show()

# Hallazgo:           [1 oracion con lo que encontraste]
# Impacto en modelo: [como afecta a tu RAG o clasificador?]
```

Minimo: 3 graficos de tipos distintos segun la tabla de decision.

Cada grafico = 1 pregunta + 1 hallazgo documentado en markdown.

Track A (RAG)

Distribucion de longitud | Tipos de documento | % que cabe en 512 tokens |
Calidad del texto

Track B (Clasificacion)

Balance de clases | Longitud por clase (boxplot) | KDE superpuestas |
Vocabulario discriminante

Guia de EDA — Track A (RAG)

? Cual es la distribucion de longitud de mis documentos?

HISTOGRAMA + KDE

Impacto: Define la estrategia de chunking

? Hay tipos distintos de documentos en mi corpus?

BARRAS

HORIZONTALES

Impacto: Indexar todo o segmentar por tipo?

? La longitud varia significativamente por tipo?

BOXPLOT POR TIPO

Impacto: Chunking diferenciado por tipo

? Que porcentaje cabe en 512 tokens?

BARRAS POR

CATEGORIA

Impacto: Factor de expansion chunks/docs

? Hay documentos con muy poco texto (< 20 palabras)?

HISTOGRAMA + UMBRAL

Impacto: Filtrar antes de indexar

Guia de EDA — Track B (Clasificacion)

¿ Cuantos ejemplos hay por clase? ¿Hay desbalance?

BARRAS ORDENADAS

¿ La longitud separa las clases?

Impacto: Feature discriminante para el modelo

BOXPLOT POR CLASE

¿ Las distribuciones de longitud se solapan?

Impacto: Solapamiento alto = modelo mas dificil

KDE SUPERPUESTAS

¿ Hay features numéricas correlacionadas?

Impacto: Evitar features redundantes

HEATMAP CORRELACION

Checklist antes de entregar

☒ REQUERIDO

- ☒ Identifique el tipo de cada variable (numerica / categorica / texto)
- ☒ Elegi el grafico usando la tabla de decision
- ☒ El titulo describe el HALLAZGO, no solo el nombre de la variable
- ☒ Los ejes tienen labels con unidades cuando corresponde
- ☒ Use alpha para evitar el overplotting en scatter plots
- ☒ El heatmap tiene mascara de triangulo y cmap diverging centrado en 0

☐ OPCIONAL

- ☐ Hay un markdown debajo de cada grafico con 1 oracion de hallazgo
- ☐ El hallazgo tiene un impacto claro en la estrategia del modelo
- ☐ Al menos 3 graficos de tipos distintos segun la tabla de decision
- ☐ Celda de resumen completada con los hallazgos del EDA

Entregable — antes de la Clase 3

- 1 Notebook Colab con EDA ejecutado sobre tu propio dataset
- 2 Al menos 3 gráficos de tipos distintos + hallazgo en markdown
- 3 Tabla resumen: tipo de doc | longitud media | problemas detectados
- 4 Celda de hallazgos completada: que aprendiste de tus datos?

El notebook de visualización (tips, titanic, penguins, iris, NLP) esta disponible como referencia.