

LEYES

LEY N° 8488

Ref. Expte. N° 91-49.969/24

EL SENADO Y LA CÁMARA DE DIPUTADOS DE LA PROVINCIA, SANCIONAN CON FUERZA DE LEY

Artículo 1°.- Los cursos o carreras en materia de salud o educación que se dicten o promocionen en el ámbito de la provincia de Salta, deben encontrarse debidamente autorizados, homologados o certificados por las Autoridades Provinciales o Nacionales competentes en la materia para su validez, en el marco de la formación docente continua.

Art. 2°.- La Autoridad de Aplicación debe habilitar canales de consulta para cotejar y verificar si la oferta educativa se encuentra correctamente certificada.

Art. 3°.- En caso de detectarse el dictado de cursos o carreras que infrinjan lo dispuesto en el artículo 1°, la Autoridad de Aplicación ordenará la suspensión inmediata del dictado y la persona humana o jurídica responsable del mismo será pasible de las siguientes sanciones:

a) Apercibimiento.

b) Multa de entre 50.000 y 100.000 unidades tributarias.

Las sanciones previstas, lo son sin perjuicio de lo dispuesto en la Sección 3ª del Capítulo 1 del Título 2, Libro Primero del Código Civil y Comercial de la Nación.

Art. 4°.- El Poder Ejecutivo Provincial determina la Autoridad de Aplicación de la presente Ley, la que coordinará acciones conjuntas con los Municipios.

Art. 5°.- Comuníquese al Poder Ejecutivo.

Dada en la Sala de Sesiones de la Legislatura de la provincia de Salta en Sesión del día seis del mes de marzo del año dos mil veinticinco.

Mashur Lapad, VICE-PRESIDENTE PRIMERO EN EJERCICIO DE LA PRESIDENCIA DE LA CAMARA DE SENADORES DE SALTA - Dr. Luis Guillermo López Mirau, SECRETARIO LEGISLATIVO DE LA CÁMARA DE SENADORES - Esteban Amat Lacroix, PRESIDENTE DE LA CÁMARA DE DIPUTADOS - Dr. Raúl Romeo Medina, SECRETARIO LEGISLATIVO DE LA CÁMARA DE DIPUTADOS

SALTA, 27 de Marzo de 2025

DECRETO N° 184
SECRETARÍA GENERAL DE LA GOBERNACIÓN
Expediente N° 91-49969/2024 - Preexistente.

EDA para NLP & RAG

V2 — VERSIÓN 2

BOLETÍN OFICIAL DE SALTA · EDICIÓN N° 21.922 · 31/03/2025

Segmentación por Patrón OP N° — Pipeline RAG para Documentos Legales de la Provincia de Salta



Corpus

Boletín Oficial de Salta — Edición N° 21.922 — 31/03/2025



Patrón

OP N°: SAXXXXXX — marcador de FIN de documento (robusto, invariante)




Resultado

12 documentos extraídos (0 filtros manuales — totalmente automático)



Mejora clave

OP N° disponible como metadata indexable → `filter(op_numero='SA100050312')`



F0 Ingesta


F1 EDA

F2 Limpieza

F3 Chunking

Fase 0.1 — Extracción de Texto del PDF con pdfplumber

Fase 0.1 — Extracción de Texto del PDF (pdfplumber)



¿Qué hace pdfplumber?

01

Acceso por página

Abre el PDF y accede a cada página como objeto independiente

02

Extracción de texto

Extrae texto con `page.extract_text()` preservando saltos de línea

03

Limpieza de cabecera

Aplica regex para eliminar la cabecera repetida en cada página

04

Corpus lineal

Concatena el texto limpio en un corpus lineal continuo

```
HEADER_RE = re.compile(
    r'Edición N\[\d\] \[\d\.\.\]+\n'
    r'Salta, \[\^\n\]+\n'
    r'Decreto Reglamentario\[\^\n\]+\n',
    re.IGNORECASE
)
```

```
for page in pdf.pages:
    raw = page.extract_text()
    clean = HEADER_RE.sub('', raw)
    corpus += clean + '\n'
```

Fase 0.2 — Segmentación por OP N°: Marcador de FIN de Documento (V2)

🔄 NUEVO V2

Estructura del Boletín Oficial

Edición N° 21.922	← BOILERPLATE
Salta, lunes 31 de marzo	← BOILERPLATE
Decreto Reglamentario N°..	← BOILERPLATE
DECRETO N° 168	
MINISTERIO DE SEGURIDAD...	
VISTO el pedido de Retiro...	
...cuerpo del documento...	
SÁENZ - Solá Usandivaras	
Fechas de publicación: 31/03/2025	
OP N°: SA100050312	← DELIMITADOR

✓ Invariante

Mismo formato en todos los boletines

✓ Único por doc

Nunca aparece en el cuerpo del documento

✓ 12 docs extraídos

vs 11 de V1 (sin filtros ad-hoc)

✓ Filtros RAG directos

op_codigo y op_numero disponibles como filtros

✓ Etiquetas OP

En todos los gráficos EDA para trazabilidad

```
PATRON_OP = re.compile(
    r'OP\\s\\s*N\\[°º\\]:\\s\\s*[A-Z]\\s*\\d{6,}',
    re.IGNORECASE
)

prev_end = 0
for op_match in PATRON_OP.finditer(corpus):
    bloque = corpus[prev_end : op_match.end()]
    op_cod = op_match.group()
    op_num = re.search(r'\\d{6,}', op_cod).group()
    prev_end = op_match.end()
```

Fechas de publicación: 31/03/2025
OP N°: SA100050295

SALTA, 21 de Marzo de 2025

DECISIÓN ADMINISTRATIVA N° 111
MINISTERIO DE EDUCACIÓN, CULTURA, CIENCIA Y TECNOLOGÍA
EXPEDIENTE N° 0120047-27207/2025-0

VISTO el pedido de afectación de la Sra. Testa, Noelia Alejandra, personal del Ministerio de Educación, Cultura, Ciencia y Tecnología de la provincia de Salta, al Concejo Deliberante de la Ciudad de Salta; y

CONSIDERANDO:

Que la afectación es una medida de excepción y de carácter transitorio, por la cual se admite la afectación en forma no permanente por parte de un agente en otra dependencia, para la realización de tareas específicas, estando su vigencia condicionada a las razones que la originaron;

Que, en tal sentido, las autoridades correspondientes prestan conformidad al presente trámite;

Por ello, con arreglo a lo establecido por el artículo 13 de la Ley N° 8171 y modificada por su similar Ley N° 8274 y el artículo 1 inciso D) de la Resolución N° 16/2021 del Ministerio de Economía y Servicios Públicos;

EL COORDINADOR ADMINISTRATIVO DE LA GOBERNACIÓN

DECIDE:

ARTÍCULO 1°.- Autorizar la afectación de la Sra. Testa, Noelia Alejandra, D.N.I N° 29.640.497, personal del Ministerio de Educación, Cultura, Ciencia y Tecnología de la provincia de Salta al Concejo Deliberante de la Ciudad de Salta, a partir del 01 de enero de 2025 y hasta el 31 de diciembre de 2025, o mientras duren las necesidades de servicio, lo que suceda primero.

ARTÍCULO 2° - El presente Acto Administrativo será refrendado por la señora Ministra de Educación, Cultura, Ciencia, y Tecnología.

ARTÍCULO 3°.- Comunicar, publicar en el Boletín Oficial y archivar.



Demitrópulos – Fiore Viñuales

Fechas de publicación: 31/03/2025
OP N°: SA100050296


SEPARADOR DE DOCUMENTOS
PATRON

Fase 0.3 — Mapa Posicional del Corpus por OP N° (exclusivo V2)


Fase 0 — Corpus V2: 12 Documentos por OP N° (automático, sin filtros manuales)



Por Tipo de Documento




Por Ministerio/Organismo



Cada barra = un documento. Ancho = tamaño en chars. Etiqueta = código OP oficial.

EDA 1.1 — Distribución de Longitud (eje = OP N°)

EDA 1.1 — Distribución de Longitud V2



Ratio promedio: 0.158 pal/char → chunk de 250 palabras ≈ 1,582 chars | chunk de 500 palabras ≈ 3,165 chars



1. Distribución de Carga (Izquierda): Los **Decretos (azul)** son los documentos más extensos, superando frecuentemente el límite crítico de **500 palabras**. Esto confirma que no podemos procesarlos como piezas únicas y que la segmentación (*chunking*) es obligatoria para evitar la pérdida de contexto en los modelos de lenguaje.

2. Correlación Morfológica (Centro): Existe una relación lineal perfecta entre palabras y caracteres en todos los tipos de documentos. El dataset es sumamente predecible, lo que nos permite automatizar el procesamiento con total confianza. El lenguaje legal aquí tiende a palabras largas (promedio de 6.3 caracteres).

3. Estabilidad del Ratio (Derecha): El ratio de **0.158 pal/char** es uniforme, sin importar si es una Ley o una Decisión Administrativa. Esta "constante" es nuestra regla de oro: nos permite fijar un **chunk size de ~3,165 caracteres** para garantizar fragmentos de 500 palabras, optimizando así la precisión de las búsquedas y el costo de tokens.

EDA 1.2 — Densidad de Stop-words en el Corpus Legal

1.2 Densidad de Stop-words



1. Prevalencia de Stop-words (Izquierda): El análisis muestra que aproximadamente el **40% de cada documento** está compuesto por palabras funcionales (*stop-words*). Esta densidad es notablemente estable en todas las categorías (Leyes, Decretos y Decisiones Administrativas), lo que indica que casi la mitad del volumen de texto no aporta carga semántica directa, pero es vital para la estructura sintáctica.

2. Identificación de Ruido vs. Contexto (Derecha): El ranking de las 20 palabras más frecuentes está liderado por conectores básicos ("de", "la", "el"). Sin embargo, el análisis destaca una distinción crítica para el dominio legal: términos como **"no"** o **"será"** (marcados para preservar) no deben ser eliminados. En el contexto normativo, una *stop-word* estándar como "no" cambia radicalmente el sentido de una obligación o prohibición.



Implicancia para el Modelo: Debido a esta alta densidad, se recomienda **no utilizar listas de stop-words genéricas**. Para este motor de búsqueda, mantendremos las palabras que definen lógica jurídica (negaciones y tiempos verbales de mandato) para asegurar que el modelo entienda correctamente las jerarquías y obligaciones legales.

EDA 1.3 — N-Gramas: Frases Compuestas del Dominio Legal

F1 — EDA

EDA 1.3 — N-Gramas: Frases Compuestas que NO deben separarse en el Chunking

△ NO separar en chunking — frase compuesta del dominio N-grama frecuente estándar



□ Detectar estas frases compuestas permite configurar los separadores del Recursive Split para no cortarlas



Las frases en rojo configuran los **separadores negativos del Recursive Split**: nunca cortar 'retiro voluntario'





🔑 N-gramas detectados → configuran los **SEPARADORES** del Recursive Split para garantizar integridad semántica en el chunking

- 'retiro voluntario' aparece 12x — frase compuesta crítica que no debe dividirse
- 'suboficial principal/mayor' — cargo + rango → preservar unidad semántica

EDA 1.4 — Similitud TF-IDF (eje Y = OP N°)

F1 — EDA


EDA 1.4 — Similitud entre Documentos y Detección de Boilerplate





Δ Decretos 168-173 (Retiro Voluntario) comparten plantilla idéntica → boilerplate repetitivo que sesga el espacio vectorial

EDA 1.5 — Outliers de Longitud (eje = OP N°)

EDA 1.5 — Outliers de Longitud: Clasificación para el Pipeline de Chunking



Categorías de Longitud



● Rango óptimo


10 de 12 documentos en rango óptimo 80–600 palabras para chunking

● Outlier corto

SA100050326 (Decreto 188 renuncia): más corto → revisar contenido

EDA 1.6 — NER: Entidades para Filtros

EDA 1.6 — NER: Análisis de Entidades para Diseño de Filtros RAG



Estos patrones NER alimentan directamente los filtros de metadatos del RAG: `tipo_entidad` → campo indexable en Chroma/Pinecone

Validación

El campo `OP_CODIGO` aparece exactamente **12 veces**
→ confirma que la segmentación es correcta (1 OP por doc)

DNI + Legajo

10+ ocurrencias por decreto → metadata de persona indexable directamente en Chroma/Pinecone

1. Distribución de Entidades (Izquierda): El modelo NER identifica el "**NÚMERO_DECRETO**" como la entidad predominante (76 ocurrencias), seguida por "**MINISTERIO**" y "**RANGO_POLICIAL**". Esta jerarquía define nuestras prioridades para la extracción automática de datos: estos campos son los candidatos naturales para convertirse en los filtros principales de búsqueda.


2. Especificidad por Documento (Derecha): Se observa una alta concentración de entidades en los **Decretos (DEC)**, mientras que las Leyes (LEY) y Decisiones Administrativas (DA) muestran una densidad mucho menor. Esto sugiere que los Decretos actúan como "nodos conectores" en el sistema, vinculando personas (DNI), instituciones (MINISTERIO) y procesos (EXPEDIENTE).

Nota clave para la slide: "La extracción de estas entidades transforma texto no estructurado en una base de conocimiento navegable, permitiendo cruzar normativas con datos duros como números de legajo o DNI."

EDA 1.7 — TTR / Lexical Richness + EDA 1.8 — Unicode


F1 — EDA

1.7 Lexical Richness — ¿Necesitamos Lematización?



1. Diversidad de Vocabulario (Izquierda): Al comparar el TTR simple (Type-Token Ratio) con el **MATTR (Moving Average TTR)**, observamos que la riqueza léxica real es significativamente alta (>0.7). Esto indica que los documentos no son repetitivos, sino que utilizan un vocabulario jurídico técnico muy variado, lo que justifica un análisis más profundo de las raíces de las palabras.

Longitud vs Riqueza Léxica (MATTR)



2. Consistencia en la Complejidad (Derecha): El gráfico de **MATTR vs Tokens** muestra que, independientemente de la extensión del documento (desde 300 hasta 1200 tokens), la riqueza léxica se mantiene estable. Los **Decretos (azul)** tienden a ser los documentos léxicamente más densos, lo que aumenta la dificultad para que una búsqueda por "palabra exacta" encuentre resultados relevantes.

"La alta sofisticación del lenguaje legal detectada exige normalización (lematización) para asegurar que la riqueza del vocabulario no se convierta en una barrera para la recuperación de información."

Próximos Pasos — Indexación y Evaluación RAG

Pipeline V2 listo para producción

```
from sentence_transformers import SentenceTransformer
import chromadb, json

# 1. Cargar JSONL generado en Fase 3
with open('boletin_salta_chunks.jsonl') as f:
    records = [json.loads(l) for l in f]

# 2. Embeddings multilingüe
model = SentenceTransformer(
    'intfloat/multilingual-e5-large'
)
embeddings = model.encode(
    [r['texto'] for r in records],
    show_progress_bar=True
)

# 3. Indexar en Chroma con metadatos
client = chromadb.Client()
col = client.create_collection('boletin_salta')
col.add(
    embeddings = embeddings.tolist(),
    documents = [r['texto'] for r in records],
    metadatas = [{k:v for k,v in r.items() if k!='texto'} for r in records],
    ids = [r['chunk_id'] for r in records]
)

# 4. Query con filtro OP – EXCLUSIVO V2
results = col.query(
    query_texts = ['Retiro voluntario policial Salta'],
    where = {'op_numero': 'SA100050312'},
    n_results = 5
)
```

01

JSONL exportado

boletin_salta_chunks.jsonl con op_codigo + 7 flags de metadatos

02

Embeddings

multilingual-e5-large o text-embedding-3-small para vectorización

03

Chroma / Pinecone

Indexar con metadatos completos — OP N° como filtro directo en queries

04

RAGS Evaluation

Métricas: **faithfulness**, **answer_relevancy**, **context_recall** por tipo de documento



Pipeline V2 completamente operativo: segmentación automática, metadatos OP N° indexables y evaluación RAG lista para producción.